

Mini-Curso: Introdução à Inteligência Artificial com Redes Neurais Artificiais



Parte 2

Professor José Francisco Pessanha

13 de dezembro de 2024

15:30 – 18:00, sala RAV62, 6º andar, bloco F

https://homeprojextransicaoenergetica.netlify.app/_site/eventos

Projeto de Extensão

TRANSIÇÃO ENERGÉTICA: vantagens e desafios técnicos das energias renováveis para o equilíbrio entre custos, segurança e mudanças climáticas



Departamento de
Estatística



ELE
Depto. de Eng. Elétrica




Redes com treinamento não supervisionado

- Neste tipo de rede fornecemos dados não rotulados, ou seja, apenas os dados de entrada (sem dados de saída). O algoritmo sozinho identifica padrões e relacionamentos nos dados.
- Mapa Auto-Organizável (Self Organizing Map – SOM): aplicações em clustering e detecção de anomalias
- Autoencoder: detecção de anomalias, geração de dados sintéticos
- *Generative Adversarial Network* (GAN): geração de dados sintéticos

Rede Auto-Organizável (Self-Organizing Map SOM)

- Proposto por Teuvo Kohonen em 1982
- Rede neural com treinamento não supervisionado
- A rede aprende as similaridades entre os padrões de entrada (reconhecimento de padrões)
- Útil na análise de agrupamentos (*cluster analysis*)



Teuvo Kohonen
1934 – 2021

Biol. Cybern. 43, 59–69 (1982) [BF00337288.pdf](#)

Biological
Cybernetics
© Springer-Verlag 1982


Self-Organized Formation of Topologically Correct Feature Maps

Teuvo Kohonen

Department of Technical Physics, Helsinki University of Technology, Espoo, Finland

Arquitetura da rede SOM


- Em geral tem apenas duas camadas interconectadas por pesos sinápticos adaptáveis:
- Camada de entrada com p neurônios
- Camada de saída com q neurônios em uma grade bidimensional (mapa)




Autoencoder

Um **autoencoder** é um tipo de rede neural projetada para aprender uma representação compacta e eficiente (codificação) dos dados, geralmente com o objetivo de compressão, redução de dimensionalidade ou aprendizado de características relevantes.


Ele é composto de duas partes principais: o **encoder** (codificador) e o **decoder** (decodificador).



Autoencoder



<https://blog.curso-r.com/posts/2017-06-26-construindo-autoencoders/>




Aplicação do Autoencoder

- 1.Redução de dimensionalidade:** Similar ao PCA (Análise de Componentes Principais), porém mais flexível, já que pode modelar relações não lineares nos dados.
- 2.Detecção de anomalias:** Como os autoencoders aprendem padrões comuns nos dados, podem ser usados para identificar exemplos que não conseguem ser reconstruídos bem (potenciais anomalias).
- 3.Compressão de dados:** Usado para comprimir dados em um formato mais eficiente, preservando informações importantes.
- 4.Pre-treinamento:** Pode ser usado para inicializar redes profundas com boas representações dos dados.
- 5.Geração de dados:** Autoencoders variantes, como o **Variational Autoencoder (VAE)**, são usados para gerar dados novos com características semelhantes aos dados originais.


Greedy layer-wise pretraining (Kelleher, 2019)

Abordagem **hierárquica e incremental** para treinar redes neurais profundas camada por camada, em vez de treinar toda a rede simultaneamente. A ideia é treinar uma camada de cada vez, garantindo que cada uma aprenda boas representações antes de passar para a próxima. **O termo "greedy" refere-se ao fato de que cada camada é treinada de forma independente, sem considerar as camadas futuras.**

Técnica de treinamento utilizada principalmente para redes neurais profundas com o objetivo de superar dificuldades associadas ao treinamento direto (end-to-end) de redes muito profundas. Essa abordagem foi especialmente popular antes do avanço de técnicas como inicializações mais robustas de pesos e otimizadores modernos (por exemplo, Adam).



Deep Autoencoder Networks



Science

Current Issue

First release papers

Archive

About ▾

Submit manuscript

HOME > SCIENCE > VOL. 313, NO. 5786 > REDUCING THE DIMENSIONALITY OF DATA WITH NEURAL NETWORKS

REPORTS

f X in 5 6 7 8

Reducing the Dimensionality of Data with Neural Networks

G. E. HINTON AND R. R. SALAKHUTDINOV [Authors Info & Affiliations](#)

SCIENCE • 28 Jul 2006 • Vol 313, Issue 5786 • pp. 504-507 • DOI: 10.1126/science.1127647

38,713 13,947

🔔 📖 🗣️

CHECK ACCESS

Reducing the Dimensionality of Data with Neural Networks

G. E. Hinton* and R. R. Salakhutdinov

High-dimensional data can be converted to low-dimensional codes by training a multilayer neural network with a small central layer to reconstruct high-dimensional input vectors. Gradient descent can be used for fine-tuning the weights in such “autoencoder” networks, but this works well only if the initial weights are close to a good solution. We describe an effective way of initializing the weights that allows deep autoencoder networks to learn low-dimensional codes that work much better than principal components analysis as a tool to reduce the dimensionality of data.

<https://www.science.org/doi/abs/10.1126/science.1127647>

Generative Adversarial Network – GAN (2014)



Ian Goodfellow
1987

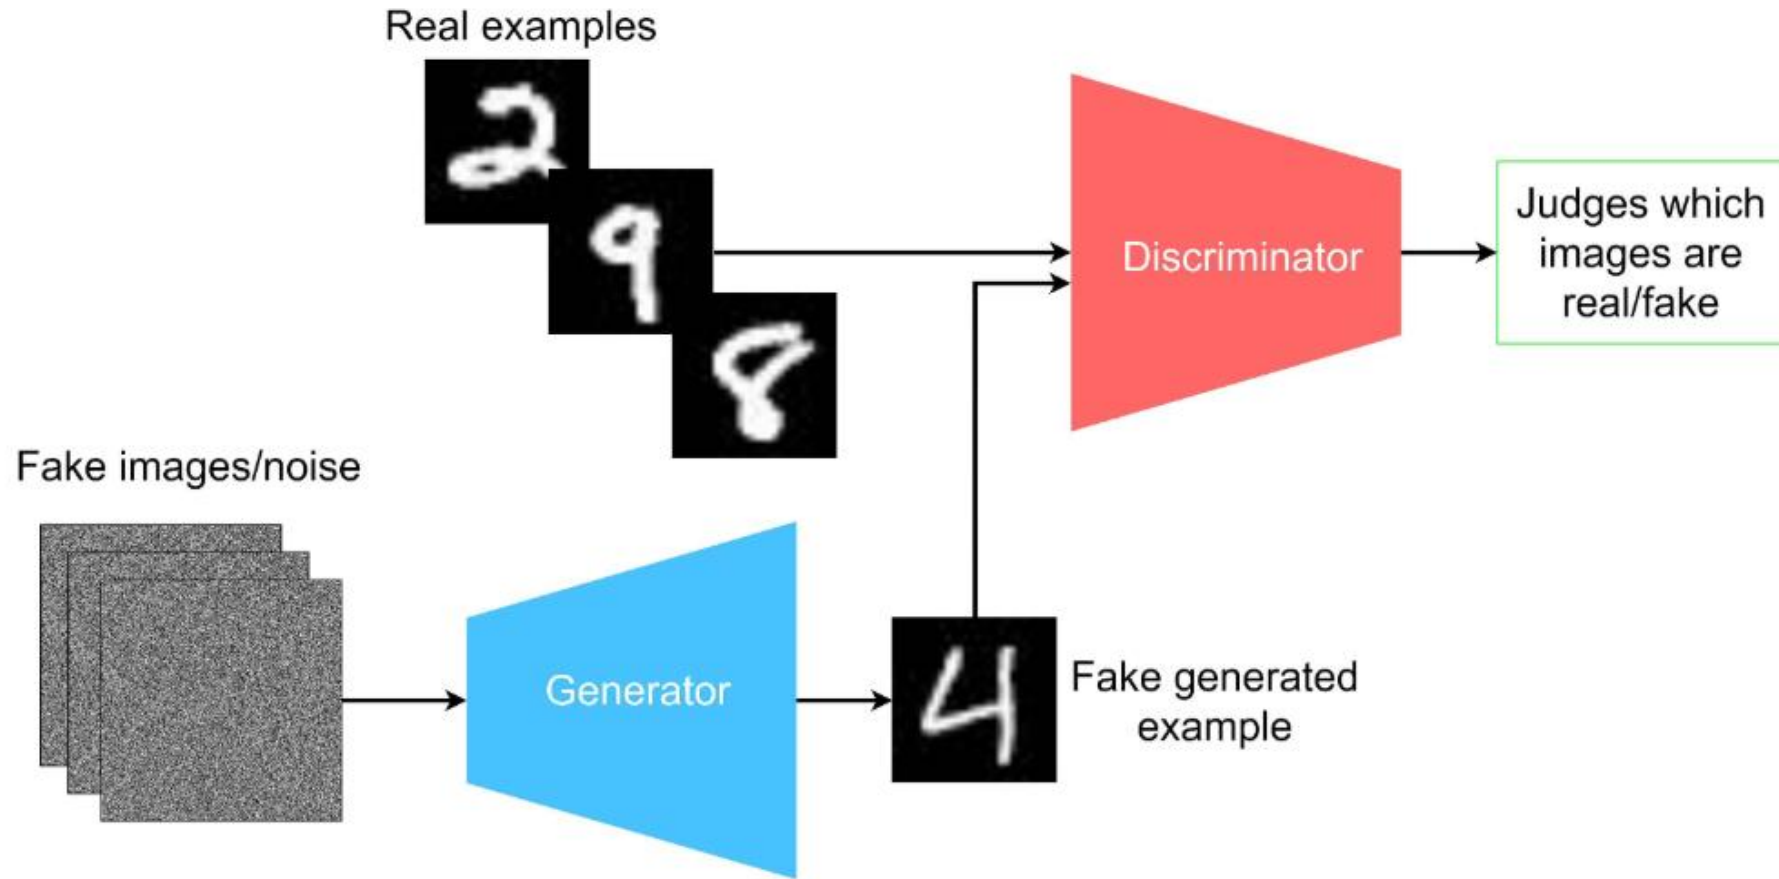
Uma **Generative Adversarial Network (GAN)** é um tipo de rede neural projetada para gerar dados novos que são indistinguíveis de dados reais.

Funciona com base em uma abordagem competitiva entre duas redes neurais: o **gerador (generator)** e o **discriminador (discriminator)**.

O objetivo do treinamento é alcançar um equilíbrio onde:

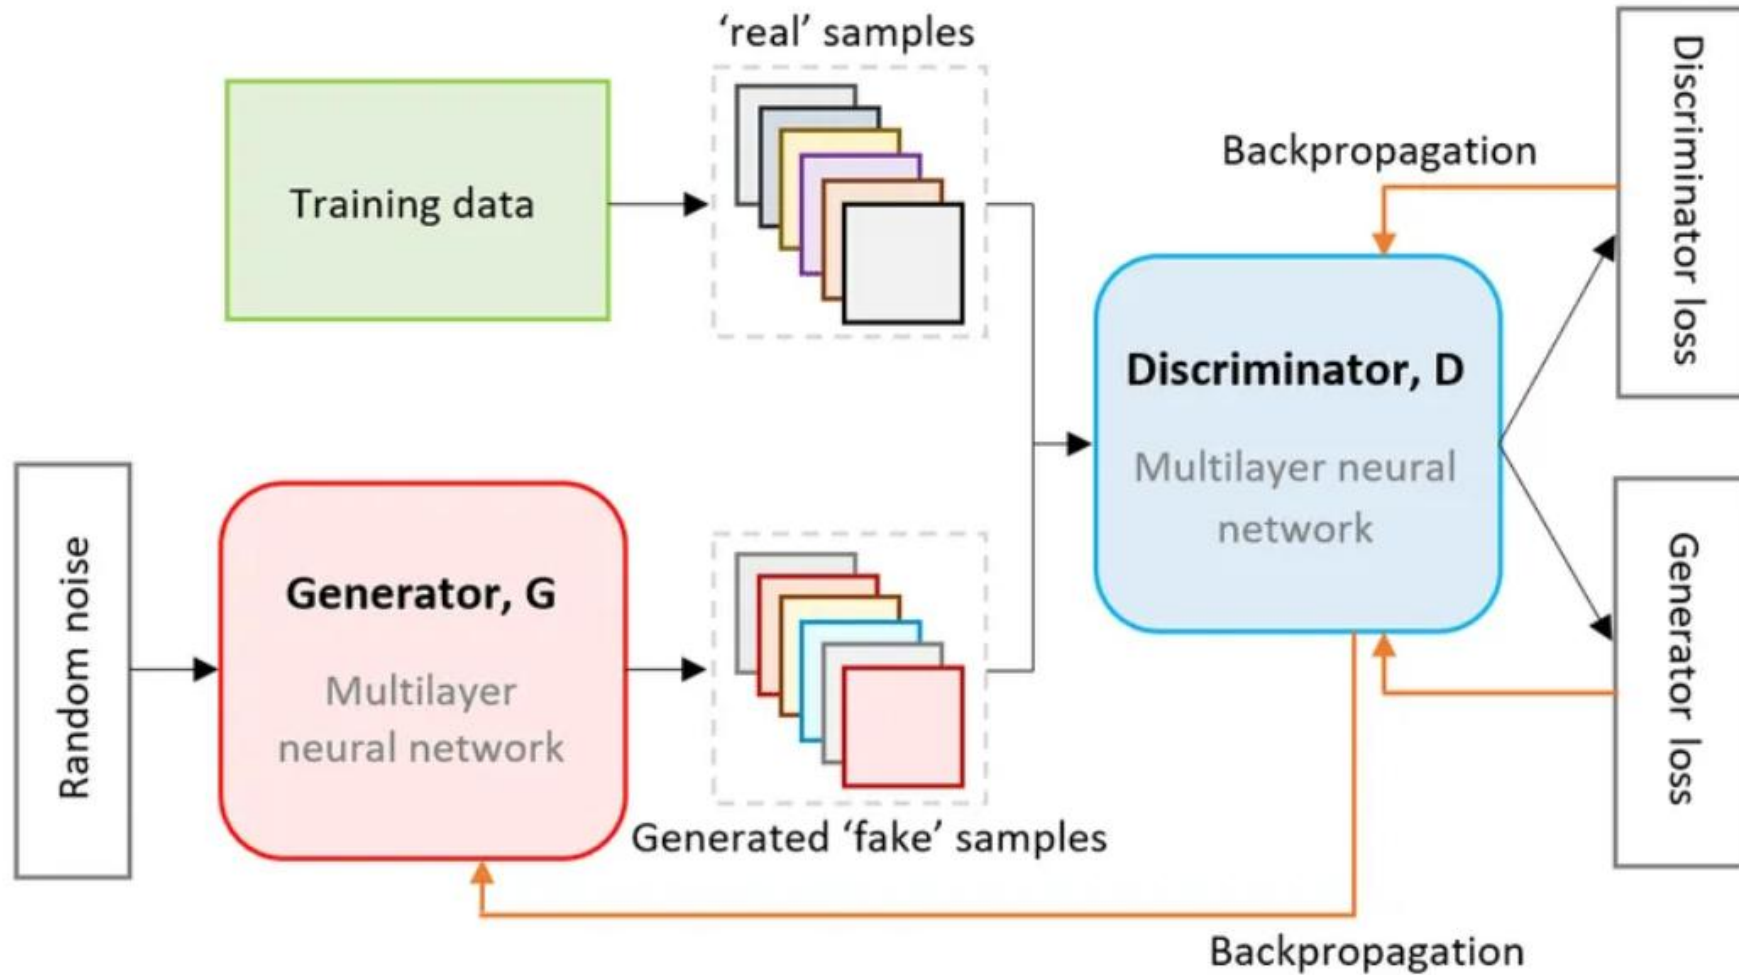
- O gerador aprende a produzir dados realistas.
- O discriminador não consegue distinguir entre os dados reais e os gerados.

Generative Adversarial Network – GAN (2014)



<https://developer.ibm.com/articles/generative-adversarial-networks-explained/>

Generative Adversarial Network – GAN (2014)



Estrutura da GAN

Estrutura de uma GAN

- **Gerador (Generator):** Tenta criar dados sintéticos que se assemelham aos dados reais.
- Recebe como entrada um vetor de ruído z (geralmente amostras de uma distribuição aleatória, como uma gaussiana) e o transforma em uma amostra $G(z)$ que simula os dados reais.
- Seu objetivo é "enganar" o discriminador.

Discriminador (Discriminator)

- Avalia os dados, classificando-os como reais (provenientes do conjunto de dados original) ou falsos (produzidos pelo gerador).
- Funciona como um classificador binário que tenta distinguir entre x (dato real) e $G(z)$ (dato gerado).

Competição (Adversarial)

- O gerador e o discriminador são treinados simultaneamente em um jogo de soma zero
- O gerador tenta maximizar as chances de o discriminador aceitar suas amostras como reais.
- O discriminador tenta minimizar os erros ao classificar corretamente dados reais e falsos.

Considerações finais

Foram apresentadas algumas arquiteturas de redes neurais artificiais para treinamento não supervisionado: SOM, Autoencoder e GAN

Aplicações apresentadas: análise de agrupamentos, detecção de anomalias e geração de dados sintéticos.

Os recursos disponibilizados pelo R e Python facilitam a implementação das redes neurais artificiais

Os códigos disponibilizados na apresentação podem ser facilmente adaptados para outras aplicações.